# wrangle\_act

June 25, 2022

# 1 Project: Wrangling and Analyze Data

## 1.0.1 Importing Useful Libraries

```
In [1]: import pandas as pd
    import numpy as np
    import requests
    import tweepy
    import json
    import time
    from timeit import default_timer as timer
```

### 1.1 Data Gathering

In the cell below, gather **all** three pieces of data for this project and load them in the notebook. **Note:** the methods required to gather each data are different. 1. Directly download the WeRate-Dogs Twitter archive data (twitter\_archive\_enhanced.csv)

#### 1.1.1 Data Information

- data\_1 = twitter\_archive\_enhanced.csv (which is already available for download)
- data\_2 = image\_predictions.tsv (queried from the udacity server)
- data\_3 = twitter\_data.json (scraped from twitter with twitter Api)

2. Use the Requests library to download the tweet image prediction (image\_predictions.tsv)

```
In [3]: # Reading the downloaded tsv file
               data_2 = pd.read_csv('image-predictions.tsv', sep='\t')
In [ ]:
    3. Use the Tweepy library to query additional data via the Twitter API (tweet_json.txt)
In [3]: # importing my keys
               import config
In [3]: tweepy.__version__
Out[3]: '4.6.0'
In [6]: # upgrading tweepy library to 4.6.0 to be able call Api v2 functions
               !pip install tweepy==4.6.0
Collecting tweepy==4.6.0
    Downloading https://files.pythonhosted.org/packages/02/cf/fab85d975d5da397bae3b855d9bccde712a8
        100% || 71kB 5.0MB/s ta 0:00:011
Collecting requests<3,>=2.27.0 (from tweepy==4.6.0)
    Downloading https://files.pythonhosted.org/packages/2d/61/08076519c80041bc0ffa1a8af0cbd3bf3e2b
        100% || 71kB 14.0MB/s ta 0:00:01
Collecting requests-oauthlib<2,>=1.2.0 (from tweepy==4.6.0)
    Downloading https://files.pythonhosted.org/packages/6f/bb/5deac77a9af870143c684ab46a7934038a53
Collecting oauthlib<4,>=3.2.0 (from tweepy==4.6.0)
    Downloading https://files.pythonhosted.org/packages/1d/46/5ee2475e1b46a26ca0fa10d3c1d479577fde
        100% || 153kB 11.8MB/s ta 0:00:01
Requirement already satisfied: urllib3<1.27,>=1.21.1 in /opt/conda/lib/python3.6/site-packages (
Requirement already satisfied: idna<4,>=2.5; python_version >= "3" in /opt/conda/lib/python3.6/s
Collecting charset-normalizer~=2.0.0; python_version >= "3" (from requests<3,>=2.27.0->tweepy==4
    Downloading https://files.pythonhosted.org/packages/06/b3/24afc8868eba069a7f03650ac750a778862d
Requirement already satisfied: certifi>=2017.4.17 in /opt/conda/lib/python3.6/site-packages (from the condadation of the condad
Installing collected packages: charset-normalizer, requests, oauthlib, requests-oauthlib, tweepy
   Found existing installation: requests 2.18.4
       Uninstalling requests-2.18.4:
            Successfully uninstalled requests-2.18.4
   Found existing installation: oauthlib 2.0.6
       Uninstalling oauthlib-2.0.6:
            Successfully uninstalled oauthlib-2.0.6
   Found existing installation: requests-oauthlib 0.8.0
       Uninstalling requests-oauthlib-0.8.0:
            Successfully uninstalled requests-oauthlib-0.8.0
   Found existing installation: tweepy 3.5.0
        Uninstalling tweepy-3.5.0:
            Successfully uninstalled tweepy-3.5.0
Successfully installed charset-normalizer-2.0.12 oauthlib-3.2.0 requests-2.27.1 requests-oauthli
```

```
In [4]: # authentication for API v1
        auth = tweepy.OAuthHandler(config.api_key, config.api_key_secret)
        auth.set_access_token(config.access_token, config.access_token_secret)
        api = tweepy.API(auth, wait_on_rate_limit=True)
In [5]: # Creating the id list to be used in the api query
        tweet_ids = data_1.tweet_id.values
In [6]: dog_tweets = []
In [7]: # parsing the tweet_ids to get data data for each id in the list
        start = timer()
        for ids in tweet_ids:
            try:
                tweet = api.get_status(ids, tweet_mode='extended')
                tweet_dict = {
                    "tweet_id":tweet.id,
                    "likes":tweet.favorite_count,
                    "retweet":tweet.retweet_count,
                    "timestamp":str(tweet.created_at)
                dog_tweets.append(tweet_dict)
                print('Sucess')
            except Exception as e:
                print("Fail")
                pass
        end = timer()
        print(end - start)
Sucess
```

Fail

Sucess

\_\_\_\_

 $\operatorname{Sucess}$ 

Sucess Sucess

Sucess

Sucess

Dacebb

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Duccobb

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Dacobb

Sucess

Sucess

 $\operatorname{Sucess}$ 

Sucess Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess

Fail

Sucess

Fail

Sucess

Fail

Sucess

Fail

Sucess

aassuu

Sucess

Fail

ıaıı

Sucess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

-

Sucess

Fail

Fail

Sucess

Ducess

Sucess

Fail

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Fail

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

 $\operatorname{Sucess}$ 

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

Sucess Sucess

Dacobb

Sucess Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Duccobb

Sucess Sucess

Sucess

bucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

bucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

. . . . . . .

Sucess

 $\operatorname{Sucess}$ 

Sucess Sucess

Sucess

Ducess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

oucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Fail

Sucess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Fail

Sucess

Ducess

 $\operatorname{Sucess}$ 

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

bucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Duccob

Sucess Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

adebba

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Duccobb

Sucess Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

bucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

 $\operatorname{Sucess}$ 

Sucess

Sucess Sucess

Sucess

Sucess

Duccob

Sucess Sucess

Sucess

bucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

-

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Ducess

Sucess

Fail

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

Sucess

Sucess

Sucess

Sucess

 $\operatorname{Sucess}$ 

Sucess Sucess

Sucess

Ducess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

bucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

bucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Dacebb

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Dacobb

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducesi

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

 $\operatorname{Sucess}$ 

Sucess

Sucess

Sucess

 $\operatorname{Sucess}$ 

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Ducess

 $\operatorname{Sucess}$ 

Sucess

Sucess

Sucess

 $\operatorname{Sucess}$ 

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Dacobb

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

Sucess

```
Sucess
2085.703390442
In [9]: # saving json file to txt file with json dump
        file_name = "tweet_json.txt"
        with open(file_name, "w") as file:
            json.dump(dog_tweets, file)
In [4]: # loading the json text file to a variable in the notebook
        with open('tweet_json.txt') as f:
            tweet_data = json.load(f)
In [5]: # Converting the json text file to pandas dataframe
        data_3 = pd.DataFrame(tweet_data)
In [15]: data_3.to_csv('tweet_data.csv')
```

# 1.2 Assessing Data

In this section, detect and document at least **eight (8) quality issues and two (2) tidiness issue**. You must use **both** visual assessment programmatic assessement to assess the data.

**Note:** pay attention to the following key points when you access the data.

- You only want original ratings (no retweets) that have images. Though there are 5000+ tweets in the dataset, not all are dog ratings and some are retweets.
- Assessing and cleaning the entire dataset completely would require a lot of time, and is not necessary to practice and demonstrate your skills in data wrangling. Therefore, the requirements of this project are only to assess and clean at least 8 quality issues and at least 2 tidiness issues in this dataset.
- The fact that the rating numerators are greater than the denominators does not need to be cleaned. This unique rating system is a big part of the popularity of WeRateDogs.
- You do not need to gather the tweets beyond August 1st, 2017. You can, but note that you won't be able to gather the image predictions for these tweets since you don't have access to the algorithm used.

```
In [16]: # Checking the top five rows of data 1
         data 1.head()
Out[16]:
                      tweet_id in_reply_to_status_id in_reply_to_user_id
         0 892420643555336193
                                                   NaN
                                                                         NaN
         1 892177421306343426
                                                   NaN
                                                                         NaN
         2 891815181378084864
                                                   NaN
                                                                         NaN
         3 891689557279858688
                                                   NaN
                                                                         NaN
         4 891327558926688256
                                                   {\tt NaN}
                                                                         NaN
                            timestamp \
         0 2017-08-01 16:23:56 +0000
         1 2017-08-01 00:17:27 +0000
         2 2017-07-31 00:18:03 +0000
         3 2017-07-30 15:58:51 +0000
         4 2017-07-29 16:00:24 +0000
                                                        source \
           <a href="http://twitter.com/download/iphone" r...</pre>
         1 <a href="http://twitter.com/download/iphone" r...</pre>
         2 <a href="http://twitter.com/download/iphone" r...</pre>
         3 <a href="http://twitter.com/download/iphone" r...</pre>
           <a href="http://twitter.com/download/iphone" r...</pre>
                                                           text retweeted_status_id \
         O This is Phineas. He's a mystical boy. Only eve...
                                                                                 NaN
         1 This is Tilly. She's just checking pup on you...
                                                                                NaN
         2 This is Archie. He is a rare Norwegian Pouncin...
                                                                                 NaN
         3 This is Darla. She commenced a snooze mid meal...
                                                                                 NaN
         4 This is Franklin. He would like you to stop ca...
                                                                                 NaN
```

```
retweeted_status_user_id retweeted_status_timestamp
         0
                                  NaN
                                                              NaN
                                  NaN
                                                              NaN
         1
         2
                                  NaN
                                                              {\tt NaN}
         3
                                  NaN
                                                              NaN
         4
                                  NaN
                                                              NaN
                                                 expanded_urls rating_numerator
         0 https://twitter.com/dog_rates/status/892420643...
                                                                               13
         1 https://twitter.com/dog_rates/status/892177421...
                                                                               13
         2 https://twitter.com/dog_rates/status/891815181...
                                                                               12
         3 https://twitter.com/dog_rates/status/891689557...
                                                                               13
         4 https://twitter.com/dog_rates/status/891327558...
                                                                               12
            rating_denominator
                                     name doggo floofer pupper puppo
         0
                                                   None
                                                           None
                             10
                                  Phineas
                                          None
                                                                 None
         1
                             10
                                    Tilly
                                           None
                                                   None
                                                           None
                                                                 None
         2
                             10
                                   Archie
                                                   None
                                                           None
                                                                None
                                           None
         3
                             10
                                    Darla None
                                                   None
                                                           None None
         4
                             10 Franklin None
                                                   None
                                                           None None
In [14]: # Assessing data programmatically using .info
         data_1.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2356 entries, 0 to 2355
Data columns (total 17 columns):
tweet id
                               2356 non-null int64
in_reply_to_status_id
                               78 non-null float64
in_reply_to_user_id
                               78 non-null float64
timestamp
                               2356 non-null object
source
                               2356 non-null object
text
                               2356 non-null object
retweeted_status_id
                               181 non-null float64
retweeted_status_user_id
                               181 non-null float64
retweeted_status_timestamp
                               181 non-null object
expanded_urls
                               2297 non-null object
                               2356 non-null int64
rating_numerator
                               2356 non-null int64
rating_denominator
name
                               2356 non-null object
                               2356 non-null object
doggo
floofer
                               2356 non-null object
                               2356 non-null object
pupper
                               2356 non-null object
puppo
dtypes: float64(4), int64(3), object(10)
memory usage: 313.0+ KB
```

In [27]: # Checking the null values in data\_1

## data\_1.isnull().sum()

```
Out[27]: tweet_id
                                           0
                                        2278
         in_reply_to_status_id
         in_reply_to_user_id
                                        2278
         timestamp
                                           0
                                           0
         source
                                            0
         text
         retweeted_status_id
                                        2175
         retweeted_status_user_id
                                        2175
         retweeted_status_timestamp
                                        2175
                                           59
         expanded_urls
         rating_numerator
                                           0
                                           0
         rating_denominator
                                           0
         doggo
                                            0
         floofer
                                            0
         pupper
                                           0
                                            0
         puppo
         dtype: int64
In [25]: data_1.notnull().sum()
Out[25]: tweet_id
                                        2356
         in_reply_to_status_id
                                          78
         in_reply_to_user_id
                                          78
         timestamp
                                        2356
                                        2356
         source
                                        2356
         text
```

retweeted\_status\_id 181  ${\tt retweeted\_status\_user\_id}$ 181 retweeted\_status\_timestamp 181 expanded\_urls 2297 rating\_numerator 2356 rating\_denominator 2356 name2356 doggo 2356 floofer 2356 2356 pupper 2356 puppo dtype: int64

# In [29]: data\_1.dtypes

Out[29]: tweet\_id int64
in\_reply\_to\_status\_id float64
in\_reply\_to\_user\_id float64
timestamp object
source object

```
object
         retweeted_status_id
                                        float64
         retweeted_status_user_id
                                        float64
         retweeted_status_timestamp
                                         object
         expanded_urls
                                         object
         rating_numerator
                                          int64
         rating_denominator
                                          int64
         name
                                         object
         doggo
                                         object
         floofer
                                         object
                                         object
         pupper
         puppo
                                         object
         dtype: object
In [15]: # Visual assessment for data 2
         data_2.head()
Out[15]:
                      tweet_id
                                                                         jpg_url \
            666020888022790149
                                https://pbs.twimg.com/media/CT4udnOWwAAOaMy.jpg
            666029285002620928
                                https://pbs.twimg.com/media/CT42GRgUYAA5iDo.jpg
                                https://pbs.twimg.com/media/CT4521TWwAEvMyu.jpg
         2 666033412701032449
         3 666044226329800704
                                https://pbs.twimg.com/media/CT5Dr8HUEAA-lEu.jpg
         4 666049248165822465
                                https://pbs.twimg.com/media/CT5IQmsXIAAKY4A.jpg
                                                        p1_dog
            img_num
                                               p1_conf
                                                                                 p2
         0
                  1
                     Welsh_springer_spaniel
                                              0.465074
                                                          True
                                                                            collie
         1
                  1
                                     redbone
                                              0.506826
                                                          True
                                                               miniature_pinscher
         2
                  1
                            German_shepherd
                                              0.596461
                                                          True
                                                                          malinois
         3
                  1
                        Rhodesian_ridgeback
                                              0.408143
                                                          True
                                                                           redbone
         4
                         miniature_pinscher
                                                          True
                                                                        Rottweiler
                  1
                                              0.560311
             p2_conf
                      p2_dog
                                                рЗ
                                                     p3_conf
                                                              p3_dog
         0 0.156665
                        True
                                Shetland_sheepdog
                                                    0.061428
                                                                True
         1 0.074192
                        True Rhodesian_ridgeback
                                                    0.072010
                                                                True
         2 0.138584
                        True
                                        bloodhound
                                                    0.116197
                                                                True
         3 0.360687
                        True
                               miniature_pinscher
                                                    0.222752
                                                                True
         4 0.243682
                        True
                                         Doberman
                                                    0.154629
                                                                True
In [16]: # Programmatic assessment for data 2
         data_2.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2075 entries, 0 to 2074
Data columns (total 12 columns):
tweet id
            2075 non-null int64
            2075 non-null object
jpg_url
img_num
            2075 non-null int64
            2075 non-null object
р1
            2075 non-null float64
p1_conf
```

text

```
2075 non-null bool
p1_dog
p2
            2075 non-null object
p2_conf
            2075 non-null float64
           2075 non-null bool
p2_dog
рЗ
            2075 non-null object
            2075 non-null float64
p3_conf
p3_dog
            2075 non-null bool
dtypes: bool(3), float64(3), int64(2), object(4)
memory usage: 152.1+ KB
In [17]: # Visual assessment for data 3
        data_3.head()
Out[17]:
            likes retweet
                                                           tweet id
                                      timestamp
        0 33820
                      7009 2017-08-01 16:23:56 892420643555336193
         1 29337
                      5302 2017-08-01 00:17:27 892177421306343426
         2 22061
                      3481 2017-07-31 00:18:03 891815181378084864
         3 36947
                      7227 2017-07-30 15:58:51 891689557279858688
         4 35315
                      7763 2017-07-29 16:00:24 891327558926688256
In [18]: # programmatic assessment for data 3
         data 3.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2327 entries, 0 to 2326
Data columns (total 4 columns):
            2327 non-null int64
likes
            2327 non-null int64
retweet
            2327 non-null object
timestamp
            2327 non-null int64
tweet_id
dtypes: int64(3), object(1)
memory usage: 72.8+ KB
```

## 1.2.1 Quality issues

- 1. The timestamp values needs to be in standard date format(+0000 should be removed)
- 2. Data type issue for the timestamp, should be in date datatype
- 3. The likes column name in data\_3 should be renamed to no\_of\_likes
- 4. The retweet column name should be retweet\_count instead of retweet in data\_3 to be more descriptive
- 5. Names in column name in data\_1 are in lower,sentence and upper case(all should be in sentence case)
- 6. Too much NaNs drop all columns with too many NaNs(retweeted\_status\_user\_id, in\_reply\_to\_user\_id, retweeted\_status\_user\_id should be dropped they have very few values in the entire dataset)

- 7. Some dog type name is in lower case, sentence case and upper case in data\_2 p1 column
- 8. Some dog type name is in lower case, sentence case and upper case in data\_2 p2 column
- 9. Some dog type name is in lower case, sentence case and upper case in data\_2 p3 column (should be consistent through out)

#### 1.2.2 Tidiness issues

- 1. Create a new column and extract the tweet source from the html tag to the new column and drop the old source column
- 2. Data\_3 needs restructuring (tweet\_id should be the first column follow by the tweet text)
- 3. Data\_1 and data\_3 should be one data table (add the retweet\_count and no\_of\_likes to data\_1)
- 4. Merge data\_2 to the new data

# 1.3 Cleaning Data

In this section, clean all of the issues you documented while assessing.

**Note:** Make a copy of the original data before cleaning. Cleaning includes merging individual pieces of data according to the rules of tidy data. The result should be a high-quality and tidy master pandas DataFrame (or DataFrames, if appropriate).

# 1.3.1 Issue #1: Tidiness Issue one

Create a new column and extract the tweet source from the html tag to the new column and drop the old source column

Define:Extract the tweet source values from the html tag to a new dataframe column called new\_source and drop the source column using str.extract function and some regular expressions to criteria for extract

#### Code

## Test

```
In [8]: data_1_copy.head()
Out[8]:
                     tweet_id
                               in_reply_to_status_id
                                                      in_reply_to_user_id
           892420643555336193
           892177421306343426
                                                  NaN
                                                                       NaN
          891815181378084864
                                                  NaN
                                                                       NaN
        3 891689557279858688
                                                                       NaN
                                                  NaN
        4 891327558926688256
                                                  NaN
                                                                       NaN
                           timestamp
           2017-08-01 16:23:56 +0000
          2017-08-01 00:17:27 +0000
        2 2017-07-31 00:18:03 +0000
        3 2017-07-30 15:58:51 +0000
        4 2017-07-29 16:00:24 +0000
                                                         text retweeted_status_id
           This is Phineas. He's a mystical boy. Only eve...
                                                                               NaN
           This is Tilly. She's just checking pup on you...
                                                                              NaN
           This is Archie. He is a rare Norwegian Pouncin...
                                                                               NaN
           This is Darla. She commenced a snooze mid meal...
                                                                               NaN
          This is Franklin. He would like you to stop ca...
                                                                               NaN
           retweeted_status_user_id retweeted_status_timestamp
        0
                                NaN
                                                            NaN
        1
                                NaN
                                                            NaN
        2
                                NaN
                                                            NaN
        3
                                NaN
                                                            NaN
        4
                                NaN
                                                            NaN
                                                expanded_urls rating_numerator
           https://twitter.com/dog_rates/status/892420643...
                                                                             13
           https://twitter.com/dog_rates/status/892177421...
                                                                             13
           https://twitter.com/dog_rates/status/891815181...
                                                                             12
        3 https://twitter.com/dog_rates/status/891689557...
                                                                             13
        4 https://twitter.com/dog_rates/status/891327558...
                                                                             12
           rating_denominator
                                   name doggo floofer pupper puppo
                                                                             new_source
        0
                                Phineas None
                                                         None None
                                                                     Twitter for iPhone
                           10
                                                  None
        1
                           10
                                  Tilly None
                                                  None
                                                         None
                                                               None
                                                                     Twitter for iPhone
        2
                                                                     Twitter for iPhone
                           10
                                 Archie None
                                                  {	t None}
                                                         None
                                                               None
        3
                                  Darla None
                                                  None
                                                         None None
                                                                    Twitter for iPhone
                              Franklin None
                                                         None None Twitter for iPhone
                           10
                                                  None
```

## 1.3.2 Issue #2: Quality Issue 1

The timestamp values needs to be in standard date format(+0000 should be removed)

## Define: Remove the +0000 in the timestamp values using string slicing method

## Code

## 1.3.3 Issue #3: Quality Issue 2

Data type issue for the timestamp, should be in date datatype

**Define:** Change the datatype of timestamp to date time

#### Code

```
In [11]: data_1_copy['timestamp'] = pd.to_datetime(data_1['timestamp'])
Test
In [12]: data_1_copy.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2356 entries, 0 to 2355
Data columns (total 17 columns):
tweet_id
                              2356 non-null int64
in_reply_to_status_id
                              78 non-null float64
in_reply_to_user_id
                              78 non-null float64
timestamp
                              2356 non-null datetime64[ns]
                              2356 non-null object
text
                              181 non-null float64
retweeted_status_id
retweeted_status_user_id
                              181 non-null float64
                              181 non-null object
retweeted_status_timestamp
                              2297 non-null object
expanded_urls
rating_numerator
                              2356 non-null int64
rating_denominator
                              2356 non-null int64
                              2356 non-null object
name
                              2356 non-null object
doggo
floofer
                              2356 non-null object
                              2356 non-null object
pupper
```

```
puppo 2356 non-null object new_source 2356 non-null object dtypes: datetime64[ns](1), float64(4), int64(3), object(9) memory usage: 313.0+ KB
```

# 1.3.4 Issue #4 and #5:Quality Issue 3 and 4

The likes and retweet column name in data\_3 should be renamed to no\_of\_likes and retweet\_count to be more descriptive

# 1.3.5 Define: Rename the column name for likes in data\_3 to no\_of\_likes and retweet to retweet\_count using .rename function

## 1.3.6 Code

Out[14]:		${\tt no\_of\_likes}$	retweet_count	timestamp	${\sf tweet\_id}$
1	0	33820	7009	2017-08-01 16:23:56	892420643555336193
	1	29337	5302	2017-08-01 00:17:27	892177421306343426
	2	22061	3481	2017-07-31 00:18:03	891815181378084864
:	3	36947	7227	2017-07-30 15:58:51	891689557279858688
	4	35315	7763	2017-07-29 16:00:24	891327558926688256

## 1.3.8 Issue #6:Quality Issue 5

Names in column name in data\_1 are in lower, sentence and upper case(all should be in sentence case)

## 1.3.9 Define:

Change names in column name in data\_1 are in sentence case using the .tittle function

## 1.3.10 Code

```
In [15]: data_1_copy['name'] = data_1_copy['name'].str.title()
1.3.11 Test
```

```
4 Franklin
```

Name: name, dtype: object

# 1.3.12 Issue #7:Quality Issue 6

Too much NaNs drop all columns with too many NaNs(retweeted\_status\_user\_id, in\_reply\_to\_user\_id, retweeted\_status\_user\_id should be dropped they have very few values in the entire dataset)

#### 1.3.13 Define:

Drop the columns with too many NaNs (retweeted\_status\_user\_id, in\_reply\_to\_user\_id, retweeted\_status\_id, retweeted\_status\_timestamp, in\_reply\_status\_id ) in data\_1 using pandas drop function

In [17]: data\_1\_copy.drop(columns = ['retweeted\_status\_user\_id', 'in\_reply\_to\_user\_id', 'retweet

## 1.3.14 Code

1

2

```
1.3.15 Test
In [18]: data_1_copy.head()
Out[18]:
                      tweet_id
                                        timestamp \
         0 892420643555336193 2017-08-01 16:23:56
         1 892177421306343426 2017-08-01 00:17:27
         2 891815181378084864 2017-07-31 00:18:03
         3 891689557279858688 2017-07-30 15:58:51
         4 891327558926688256 2017-07-29 16:00:24
                                                         text \
         O This is Phineas. He's a mystical boy. Only eve...
         1 This is Tilly. She's just checking pup on you...
         2 This is Archie. He is a rare Norwegian Pouncin...
         3 This is Darla. She commenced a snooze mid meal...
         4 This is Franklin. He would like you to stop ca...
                                                expanded_urls rating_numerator
         0 https://twitter.com/dog_rates/status/892420643...
                                                                             13
         1 https://twitter.com/dog_rates/status/892177421...
                                                                             13
         2 https://twitter.com/dog_rates/status/891815181...
                                                                             12
         3 https://twitter.com/dog_rates/status/891689557...
                                                                             13
         4 https://twitter.com/dog_rates/status/891327558...
                                                                             12
           rating_denominator
                                   name doggo floofer pupper puppo
                                                                             new_source
                                                                   Twitter for iPhone
         0
                            10
                                 Phineas None
                                                 None
                                                         None None
```

Tilly None

Archie None

None

None

None None Twitter for iPhone

None None Twitter for iPhone

10

10

```
3 10 Darla None None None None Twitter for iPhone 4 10 Franklin None None None Twitter for iPhone
```

# 1.3.16 Issue #8, #9 and #10:Quality Issue 7, 8, 9

Some dog type name is in lower case, sentence case and upper case in data\_2 p1,p2 and p3 column

#### 1.3.17 Define:

Change all the dog type names case in data\_2 to title case for all the predictions columns

## 1.3.18 Code

```
1.3.19 Test
In [20]: data_2_copy.head()
Out[20]:
                      tweet_id
                                                                        jpg_url \
         0
          666020888022790149
                               https://pbs.twimg.com/media/CT4udnOWwAAOaMy.jpg
         1
           666029285002620928
                               https://pbs.twimg.com/media/CT42GRgUYAA5iDo.jpg
                               https://pbs.twimg.com/media/CT4521TWwAEvMyu.jpg
         2 666033412701032449
                               https://pbs.twimg.com/media/CT5Dr8HUEAA-1Eu.jpg
           666044226329800704
           666049248165822465
                               https://pbs.twimg.com/media/CT5IQmsXIAAKY4A.jpg
            img_num
                                              p1_conf p1_dog
                                                                               р2
                                                                                   \
                                        p1
         0
                    Welsh_Springer_Spaniel
                  1
                                            0.465074
                                                        True
                                                                           Collie
         1
                  1
                                    Redbone
                                            0.506826
                                                         True Miniature_Pinscher
                            German_Shepherd
         2
                  1
                                            0.596461
                                                        True
                                                                        Malinois
         3
                  1
                        Rhodesian_Ridgeback
                                            0.408143
                                                         True
                                                                          Redbone
         4
                        Miniature_Pinscher
                                            0.560311
                  1
                                                         True
                                                                      Rottweiler
            p2_conf p2_dog
                                               рЗ
                                                   p3_conf p3_dog
         0 0.156665
                        True
                                Shetland_Sheepdog 0.061428
                                                               True
         1 0.074192
                        True Rhodesian_Ridgeback 0.072010
                                                               True
         2 0.138584
                        True
                                      Bloodhound 0.116197
                                                               True
         3 0.360687
                        True
                              Miniature_Pinscher 0.222752
                                                               True
         4 0.243682
                        True
                                        Doberman 0.154629
                                                               True
```

# 1.3.20 Issue #11:Tidiness Issue 2

Data\_3 needs restructuring (tweet\_id should be the first column follow by the tweet text)

#### 1.3.21 Define:

Rearrange the columns indexes such that tweet\_id will be in he first column using iloc

#### 1.3.22 Code:

```
In [21]: data_3_copy = data_3_copy.iloc[:, [3, 2, 1, 0]]
```

## 1.3.23 Test:

```
In [22]: data_3_copy.head()
```

Out[22]:		${\tt tweet\_id}$	ti	mestamp	retweet_count	no_of_likes
	0	892420643555336193	2017-08-01 1	L6:23:56	7009	33820
	1	892177421306343426	2017-08-01 0	00:17:27	5302	29337
	2	891815181378084864	2017-07-31 0	00:18:03	3481	22061
	3	891689557279858688	2017-07-30 1	L5:58:51	7227	36947
	4	891327558926688256	2017-07-29 1	16:00:24	7763	35315

#### 1.3.24 Issue #12:Tidiness Issue 3

Data\_1 and data\_2 should be one data table and merge with data\_2 useful criterials (add the retweet\_count and no\_of\_likes to data\_1)

## 1.3.25 Define:

join the no\_of\_likes and retweet\_count columns in data\_2\_copy to data\_1\_copy to make new cleaned data using pd.merge function

## 1.3.26 Code

data\_1 and data\_2 copy was merged in the above code using inner join to avoid creating new nans and dirty the new cleaned datas because the rows of the two datasets are not equal

## 1.3.27 Test

```
In [24]: cleaned_archive_tweets.head()
```

```
Out[24]: tweet_id timestamp \
0 892420643555336193 2017-08-01 16:23:56
1 892177421306343426 2017-08-01 00:17:27
2 891815181378084864 2017-07-31 00:18:03
3 891689557279858688 2017-07-30 15:58:51
4 891327558926688256 2017-07-29 16:00:24

text

O This is Phineas. He's a mystical boy. Only eve...
1 This is Tilly. She's just checking pup on you...
2 This is Archie. He is a rare Norwegian Pouncin...
3 This is Darla. She commenced a snooze mid meal...
4 This is Franklin. He would like you to stop ca...
```

```
expanded_urls rating_numerator
         0 https://twitter.com/dog_rates/status/892420643...
                                                                             13
         1 https://twitter.com/dog_rates/status/892177421...
                                                                             13
         2 https://twitter.com/dog_rates/status/891815181...
                                                                             12
         3 https://twitter.com/dog_rates/status/891689557...
                                                                             13
         4 https://twitter.com/dog_rates/status/891327558...
                                                                             12
            rating_denominator
                                    name doggo floofer pupper puppo
         0
                            10
                                 Phineas None
                                                  None
                                                         None
                                                               None
         1
                                   Tilly None
                                                  None
                                                         None None
                            10
         2
                            10
                                  Archie None
                                                  None
                                                         None None
         3
                                   Darla None
                                                         None None
                            10
                                                  None
         4
                            10 Franklin None
                                                  None
                                                         None None
                    new_source no_of_likes retweet_count
         O Twitter for iPhone
                                      33820
                                                      7009
         1 Twitter for iPhone
                                      29337
                                                      5302
         2 Twitter for iPhone
                                      22061
                                                      3481
         3 Twitter for iPhone
                                      36947
                                                      7227
         4 Twitter for iPhone
                                      35315
                                                      7763
In [25]: cleaned_archive_tweets.shape
```

## 1.3.28 Issue #13:Tidiness Issue 3

Out[25]: (2327, 14)

subset the data\_2\_copy with only the first predictions, image url and tweet\_id and merge it to the new cleaned archive data

#### 1.3.29 Define:

Join column p1,tweet\_id and img\_url in table 2 to the new cleaned archive dataset using the inner join

## 1.3.30 Code

```
3 891689557279858688 2017-07-30 15:58:51
4 891327558926688256 2017-07-29 16:00:24
                                                text
  This is Phineas. He's a mystical boy. Only eve...
1 This is Tilly. She's just checking pup on you...
2 This is Archie. He is a rare Norwegian Pouncin...
3 This is Darla. She commenced a snooze mid meal...
4 This is Franklin. He would like you to stop ca...
                                       expanded_urls rating_numerator
0 https://twitter.com/dog_rates/status/892420643...
                                                                    13
1 https://twitter.com/dog_rates/status/892177421...
                                                                    13
2 https://twitter.com/dog_rates/status/891815181...
                                                                    12
3 https://twitter.com/dog_rates/status/891689557...
                                                                    13
4 https://twitter.com/dog_rates/status/891327558...
                                                                    12
   rating_denominator
                           name doggo floofer pupper puppo \
0
                                                None
                                                     None
                   10
                        Phineas None
                                         None
1
                   10
                                                None None
                          Tilly
                                None
                                         None
2
                   10
                         Archie None
                                         None
                                                None
                                                      None
3
                   10
                          Darla None
                                         None
                                                None None
                   10 Franklin None
                                         None
                                                None None
           new_source no_of_likes retweet_count
O Twitter for iPhone
                             33820
                                             7009
1 Twitter for iPhone
                             29337
                                             5302
2 Twitter for iPhone
                             22061
                                             3481
3 Twitter for iPhone
                             36947
                                             7227
4 Twitter for iPhone
                                             7763
                             35315
                                           jpg_url
                                                             р1
O https://pbs.twimg.com/media/DGKD1-bXoAAIAUK.jpg
                                                         Orange
1 https://pbs.twimg.com/media/DGGmoV4XsAAUL6n.jpg
                                                      Chihuahua
2 https://pbs.twimg.com/media/DGBdLU1WsAANxJ9.jpg
                                                      Chihuahua
                                                    Paper_Towel
3 https://pbs.twimg.com/media/DF_q7IAWsAEuuN8.jpg
4 https://pbs.twimg.com/media/DF6hr6BUMAAzZgT.jpg
                                                         Basset
```

# 1.4 Storing Data

Save gathered, assessed, and cleaned master dataset to a CSV file named "twitter\_archive\_master.csv".

```
In [28]: master_archive_cleaned.to_csv('twitter_archive_master.csv')
In [3]: master_archive_cleaned = pd.read_csv('twitter_archive_master.csv')
```

# 1.5 Analyzing and Visualizing Data

In this section, analyze and visualize your wrangled data. You must produce at least three (3) insights and one (1) visualization.

## 1.5.1 Insights:

- 1. Which dog specie has the highest prediction count in prediction 1
- 2. Which dog tweet has the highest count of retweet
- 3. The most frequent source of dog's tweet

## 1.5.2 First Insight: Which dog specie has the highest prediction count in the first prediction

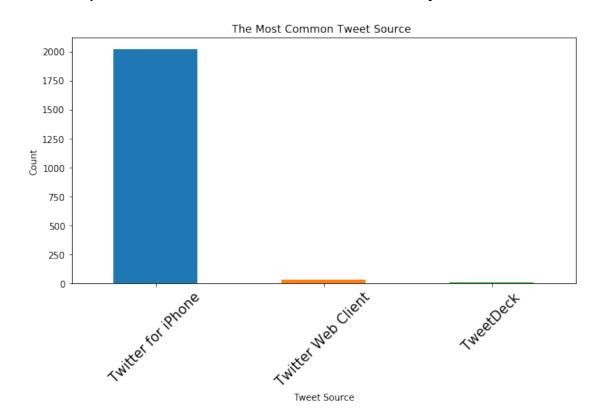
The result above shows the brief summary of prediction column in the cleaned dataset, which reveals that dog specie with the highest prediction count in prediction 1 is Golden\_Retriever with the prediction count of 150

## 1.5.3 Second Insight: Which dog tweet has the highest count of retweet

The results above reveals the dog tweets with the highest retweet count between 2015 to 2017 tweet datas in the dataset

## 1.5.4 Third Insight: What is the most common source of dog's tweet between 2015 to 2017

## 1.5.5 Visualization



The data visualization above shows the dogs tweets source by count

In []: